Université de Valenciennes et du Hainaut-Cambrésis

M2C - Malware Clustering et Classification

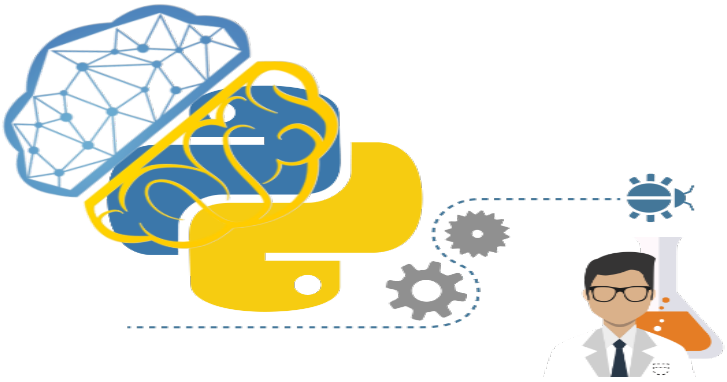

Vincent Romé - Axel Foulon - Julien Dupagny

vrome/afoulon/jdupagny@etu.univ-valenciennes.fr

— 9 Juin 2018 —

HISTORIQUE DES VERSIONS			
DATE	VERSION	ÉVOLUTION DU DOCUMENT	RÉDACTEUR
9/06/2018	0.1	Version préliminaire	Équipe complète

Table des matières

Notice légale

Le présent document présente et exprime, sauf indication contraire, le fruit de la recherche de la réflexion, des idées et du développement d'une solution pouvant répondre aux besoins et aux spécifications du marché de la cyber sécurité en matière de détection de malware. Ce document doit être considéré dès lors comme les points de vue et interprétation des auteurs. Ce document ne reflète pas nécessairement l'état de la technologie la plus récente et pourrait faire l'objet de mises à jour.

Les sources tierces seront citées, le cas échéant, l'équipe du projet acceptera d'étudier toute requête en cas d'oubli cependant elle ne reste pas responsable du contenu des sources extérieures. Le dit document a une vocation strictement informative. Toute personne possédant un exemplaire de ce document pourra être tenu responsable de l'usage qu'il pourrait en faire.

Introduction

Jusqu'à présent, les systèmes de détection d'intrusion reposaient traditionnellement sur des signatures générées manuellement par des experts en sécurité, puis nous avons vu apparaître des systèmes permettant de détecter des patterns entre des jeux de données ce qui a permis de générer automatiquement ces règles. Aujourd'hui avec l'apparition du "big data", des solutions comme le deep learning ou machine learning sont souvent présentés comme les technologies pouvant révolutionner les systèmes de détections et les performances. Ces systèmes permettent de générer automatiquement un modèle de détection à partir de données et leurs capacités à généraliser les événements malveillants permettait en effet de détecter des éléments encore inconnus.

L'objectif est ici de comprendre le fonctionnement de ces algorithmes et de les appliquer au milieu de la sécurité informatique, d'exposer les résultats de notre recherche sur la détection de fichier PE (exécutable windows malveillants). Tout en gardant un regard critique sur les résultats et en essayant d'apporter des solutions sur l'utilisation de tels algorithmes en production.

Un modèle de détection supervisée est construit à partir de données labellisées fournies par l'expert : des événements bénins, mais aussi des événements malveillants pour guider le modèle de détection. L'algorithme d'apprentissage va automatiquement chercher les points permettant de caractériser chacune des classes ou de les discriminer pour construire le modèle de détection.

Abstract

Until now, intrusion detection systems have traditionally relied on signatures generated manually by security experts, and we have seen systems for detecting patterns between datasets that have automatically generated these patterns. rules. Today with the emergence of ”big data”, solutions such as deep learning or machine learning are often presented as technologies that can revolutionize detection systems and performance. These systems make it possible to automatically generate a detection model from data and their ability to generalize malicious events made it possible to detect unknown elements.

The goal here is to understand the operation of these algorithms and apply them to the computer security environment, to expose the results of our search on PE file detection (executable malicious windows). While keeping a critical eye on the results and trying to provide solutions on the use of such algorithms in production.

A supervised detection model is built from labelled data provided by the expert : benign events, but also malicious events to guide the detection model. The learning algorithm will automatically look for the points to characterize each of the classes or to discriminate them to build the detection model.

Contexte du projet

Le Master CDSI (Cyber-Défense et Sécurité de l'Information) est une formation qui a pour objectif de fournir les compétences scientifiques aux concepts, méthodes et techniques de traitement de la sécurité et de la gestion du risque liée aux systèmes d'informations et sachant protéger les ressources d'un système d'information.

Cette formation peut être effectuée en formation initiale ou en formation continue. Elle dépend de l'ISTV (Institut des Sciences et Techniques de Valenciennes. Ce document constitue le mémoire d'un projet universitaire ayant été réalisé dans le cadre de ce master en formation universitaire sur le campus de Maubeuge.

Dans le cadre des modules "Programmation distribuée et sécurité" et "Sécurité des systèmes embarqués", nous avons eu l'occasion de réaliser un travail pratique sur le ML (Machine Learning).

Les contraintes

Il est dès à présent nécessaire de prendre en compte plusieurs contraintes que nous ne devons pas perdre de vu :

- Prédiction rapide ;
- Mise à jour périodique du modèle ;
- Interprétable (Expert puisse comprendre le modèle et l'ajuster).

Les objectifs

A travers ce projet nous voulons fournir une solution permettant la classification et une détection via des algorithmes de machine learning de malwares touchant les systèmes d'exploitation Windows de Microsoft.

Nous pourrons découvrir le principe de base d'une analyse statique de fichier malveillant ainsi que les notions relatives au machine learning et la data science pour le traitement de gros flux de données. Il s'agit d'une application particulière en matière de sécurité informatique des nouveaux algorithmes qui ont le vent en poupe.

L'objectif est qu'à l'issue de ce projet, nous soyons en mesure de comprendre les notions de base relative à :

- L'analyse de malwares ;
- Les algorithmes d'apprentissage automatique ;
- La compréhension du workflow associé à l'utilisation de tels algorithmes.

A l'issue de ce projet, un PoC d'implémentation en Python devra être disponible. Des premiers résultats permettront de conclure sur l'efficacité et la complexité ainsi que les limitations de tels algorithmes appliqués dans le domaine de la sécurité.

Première partie

Généralités

Les formes d'analyses de malware

7.1 Analyse statique

L'analyse statique peut être vu comme le fait de "lire" le fichier malware sans l'exécuter afin d'essayer d'émettre des hypothèses sur son fonctionnement à partir de ces propriétés. Il existe plusieurs techniques qui peuvent être utilisées afin d'effectuer ce type d'analyse. Voici des exemples :

1. L'analyse du format du fichier (parsing) : La structure du fichier est standardisée, elle nous permet d'en extraire des métadonnées qui peuvent être utiles. Par exemple : les fichiers importés, la date de compilation etc. … ;
2. L'extraction de chaînes de caractères ;
3. Dissasembly : Cette technique consiste à faire du reverse engineering des instructions assembleurs du programme afin de comprendre la logique interne de celui-ci.

Cette technique de détection a donc pour objectif de classifier les échantillons sans les exécuter, Celle-ci possède l'avantage d'être une couche de protection lorsque la détection fonctionne, car elle permet de détecter des fichiers malveillant avant qu'ils ne soient exécutés.

7.2 Analyse dynamique

L'analyse dynamique observe le comportement actif des malwares lorsqu'ils s'exécutent dans un environnement confiné appelé "sandbox". Celle-ci observe également le comportement de l'échantillon analysé tandis qu'il s'exécute.

Durant son exécution, des sondes notent tout ce que fait l'échantillon analysé (création de fichier, destruction de fichier, modification de fichier, modification de composants du système d'exploitation (installation d'un crochetage d'une fonction système (hook), modification du MBR (Master Boot Record), injection de code dans des pilotes (drivers), substitution d'un composant par un autre, hijack de certains réglages, ouverture (lecture) de fichiers, etc. …)), téléchargements de fichiers, envoie d'informations à l'extérieur, modification du Registre Windows, modification du contenu de la mémoire RAM, etc. …

Une intervention humaine est possible avec l'aide d'un logiciel spécifique, appelé "debugger" qui permet de suivre pas à pas les instructions exécutées et les contenus des variables.

Certaines malveillances s'aperçoivent que l'on est en train de l'exécuter dans une "sandbox" ou une machine virtuelle et se tuent elles-mêmes ou n'exécutent pas leurs charges actives.

Malware Taxonomy

Pour avoir une meilleure compréhension des méthodes et de la logique derrière les logiciels malveillant dit malware, nous pouvons les classer selon l'objectif visé par le pirate. Les grandes classes sont les suivantes :

1. Les virus ;
2. Les vers - Worm ;
3. Les chevaux de troie - Trojan ;
4. Les portes dérobées - Backdoor ;
5. Les rootkits ;
6. Les robots - Bot ;
7. Downloader ;
8. Reverse Shell ;
9. Bootkit ;
10. Potentially Unwanted Program (PUP).

La méthode la plus couramment utilisée dans les logiciels de détection de logiciels malveillants est basée sur la signature de détection. Une signature correspond à une chaîne de bits qui permet d'identifier de manière unique un malware. Cependant, cette technique est uniquement capable d'identifier un petit sous-ensemble de menaces émergentes. Il est incapable d'identifier de façon formel les nouveaux malwares. Il est donc intéressant de s'intéresser à d'autres méthodes.

Le Format PE

Nous avons décidé de travailler uniquement sur des malwares Windows afin de ne pas compliquer le sujet. Nous sommes parties du constat que la majorité des personnes utilisent ce système d'exploitation. Le format PE (Portable Executable, executable portable) est le format prédominant des fichiers exécutables et des bibliothèques sur les systèmes d'exploitation Windows 32 bits et 64 bits.

Ce format est utilisé chez Microsoft pour les pilotes, les programmes, mais aussi les DLL et autres fichiers exécutables. Ce format est dit portable car il peut être porté sous les différents systèmes que Windows NT supporte et il est cross architecture, il supporte des architectures (ARM, AMD et Intel).

Les fichiers au format PE peuvent être divisés en plusieurs parties :

En-tête MZ-DOS
Permet à Windows de reconnaître le fichier comme un exécutable. Il contient notamment le magic number MZ.

Segment DOS
Exécuté lorsque le programme est lancé en MS-DOS. La plupart du temps il affiche le message : "This program must be run under Win32".

En-tête PE
Contient des informations sur le binaire comme sa date de compilation ou encore sa signature.

Table des sections
Un fichier standard PE contient généralement : Une section .text (section de code), une ou plusieurs sections de données (.data, .rdata ou .bss) ainsi que des tables de relocation généralement stockées dans la section ".reloc".

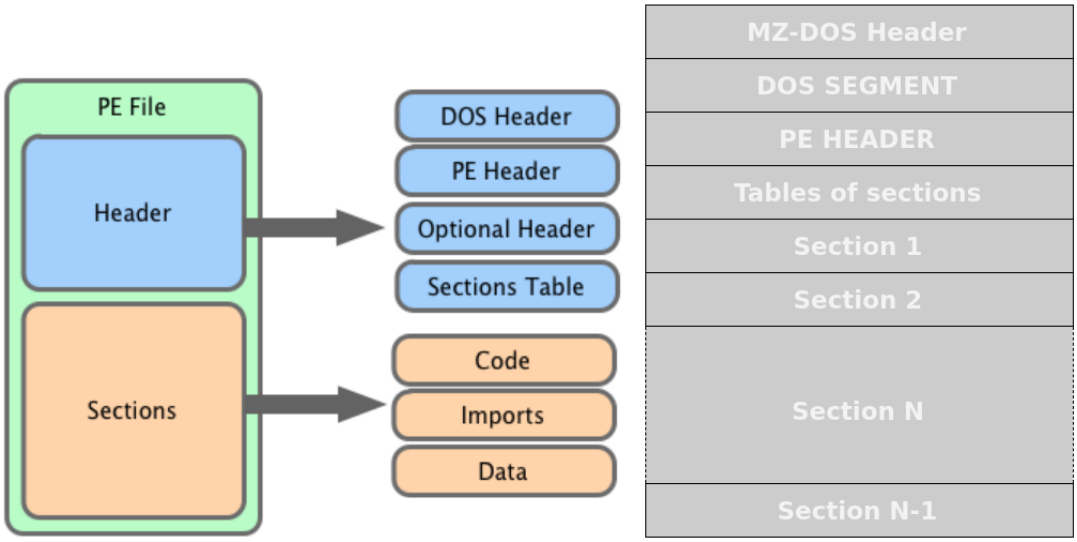

Un fichier standard PE contient généralement :

- Une section .text (section de code) ;
- Une ou plusieurs sections de données (.data, .rdata ou .bss) ;
- Des tables de relocation généralement stockées dans la section ".reloc".

Une autre partie où l'on trouve les sections. Les sections sont en fait des sortes de répertoires dans lesquels sont regroupées des données ayant la même fonctionnalité, du code ou des ressources par exemple, sous un même attribut, qui peut être en lecture seule et écriture par exemple. Il faut donc bien voir ce système de sections qui est présent tout le reste du fichier. Ces sections contiennent le code, quelques informations sur le chargement en mémoire du fichier ou encore des informations de débogage.

Le Fuzzy hashing

Il s'agit d'un outil dit de fuzzy hashing qui signifie qu'une valeur de hash essaie de détecter le niveau de similarité entre deux fichiers au niveau binaire. Ce type de hash est différent d'un hash cryptographique tel que SHA-1 car un hash cryptographique standard permet de répondre à la question "C'est deux fichiers sont-ils identiques ?". Un fuzzy hash aussi appelé "similarity hash" lui est utile pour répondre à la question "Une partie de ce fichier est-elle là même que ce second ?".

Les deux grands algorithmes de fuzzy hashing utilisés pour la classification de malwares sont :

- **ssdeep :** Basé sur un détecteur de spam appelé "spamsum" ;
- **machoke :** Algorithme de fuzzy hashing basé sur le CFG.

Il peut donc être intéressant d'utiliser ce hash comme feature. Nous n'avons malheureusement pas eu le temps de tester cette possibilité.

Les différents type de ML

En matière d'apprentissage automatisé, on oppose très fréquemment apprentissage supervisé et apprentissage non supervisé. Bien que les deux types d'apprentissages relèvent de l'intelligence artificielle, il est important de comprendre que ces deux types d'apprentissages ne sont par nature pas adaptés aux mêmes types de situations.

11.1 Supervisé

Dans le cas du supervisé, un chercheur est là pour "guider" l'algorithme sur la voie de l'apprentissage en lui fournissant des exemples qu'il estime probants après les avoir préalablement étiquetés des résultats attendus. L'intelligence artificielle apprend alors de chaque exemple, avec pour but, d'être capable de généraliser son apprentissage à de nouveaux cas.

Si cette solution semble idéale sur le papier, car elle ne nécessite pas de grands jeux de données dont les résultats attendus sont connus.

11.2 Non supervisé

Dans le cas de l'apprentissage non supervisé, l'apprentissage par la machine se fait de façon totalement autonome. Des données sont alors communiquées à la machine sans lui fournir les exemples de résultats attendus en sortie.

L'apprentissage non supervisé est principalement utilisé en matière de clusterisation, procédé destiné à regrouper un ensemble d'éléments hétérogènes sous forme de sous groupes homogènes ou liés par des caractéristiques communes. La machine fait alors elle-même les rapprochements en fonction de ces caractéristiques qu'elle est en mesure de repérer sans nécessiter d'intervention externe. De cette capacité à effectuer de la clusterisation découle également la possibilité de mettre au point un système de recommandation (le système peut par exemple recommander un livre ou un film à un utilisateur en fonction des goûts d'utilisateurs partageant des caractéristiques communes) ainsi que la possibilité de mettre au point un système de détection d'anomalies.

11.3 Les algorithmes

11.3.1 Classification

La classification est une technique de machine learning supervisée qui est habituellement divisée en deux phases : La première phase consiste à former un classificateur en utilisant un algorithme de

classification sur la base d'échantillon labellisé.

Quand la variable à prédire prend une valeur discrète, on parle d'un problème de classification. Parmi les algorithmes de classification, on retrouve : Support Vector Machine (SVM), Réseaux de neurones, Naïve Bayes, Logistic Regression etc. ...

Chacun de ses algorithmes a ses propres propriétés mathématiques et statistiques. En fonction des données d'entrainement (Training set), et nos features, on optera pour l'un ou l'autre de ces algorithmes. Toutefois, la finalité est la même : pouvoir prédire à quelle classe appartient une donnée (ex : un nouveau email est il spam ou non).

Quand l'ensemble des valeurs possibles d'une classification dépasse deux éléments, on parle de classification multi-classes (Multi-class Classification). L'image suivante illustre les deux types de classifications.

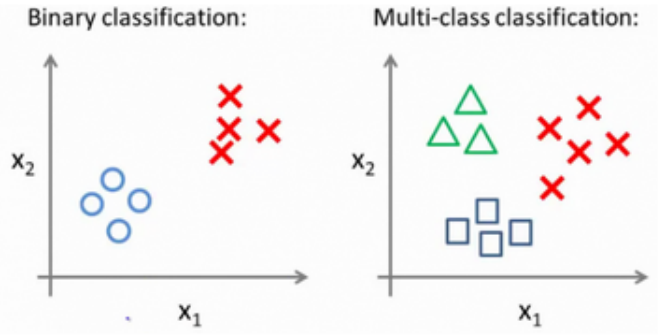

Dans l'image ci-dessus, les ronds en bleu représentent une classe (mail non spam par exemple), et les croix rouges peuvent représenter des SPAM. L'image à droite est une multi-class classification, car nous avons trois classes possibles (les triangles, les croix, et les carrés).

11.3.2 Clustering

Le clustering est une technique de machine learning non supervisé qui permet de regrouper des données utilisant des similarités entre deux fichiers. Ceci signifie que des fichiers dans un même cluster (famille) sont très similaires les un des autres.

KMeans

Kmeans est l'un des algorithmes de clustering les plus populaire. Cette algorithme a pour objectif de partitionner n échantillons différents dans k clusters dans lequel chaque échantillons du même algorithme regroupe les données en essayant de séparer les échantillons dans n groupes de variance ég.

Cet algorithme est bien adapté au grand nombre d'échantillons et au travers d'un large éventail de domaines très différents.

L'algorithme k-means divise un ensemble de N échantillons (samples) X en K cluster disjoints C, chacun décrit par la moyenne des échantillons dans le cluster. Les moyens sont communément appelés le cluster "centroïdes". On peut remarquer qu'ils ne sont pas, en général, des points de X, bien qu'ils vivent dans le même espace. L'algorithme KMeans vise à choisir des centroïdes qui minimisent l'inertie, ou la somme intra-cluster du carré critère.

DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est un algorithme de partitionnement de données proposé en 1996 par Martin Ester, Hans-Peter Kriegel, Jörg Sander et Xiaowei Xu1. Il s'agit d'un algorithme fondé sur la densité dans la mesure qui s'appuie sur la densité estimée des clusters pour effectuer le partitionnement.

L'algorithme cherche les groupes de points proches. Pour cela, il recherche, pour chaque point, les points faisant partie de son voisinage immédiat et il regroupe tous les points atteignables de proche en proche. Une fois tous les points regroupés, les groupes de points sont considérés soit comme des clusters soit comme des valeurs aberrantes, si le nombre d'observations est inférieur à MinPoints.

Avec DBSCAN, il n'est pas nécessaire de connaitre en avance le nombre de cluster désiré. De plus, l'algorithme détecte et isole de lui-même les valeurs aberrantes. L'algorithme peut créer des clusters ayant des formes quelconques.

Concernant, la complexité et le passage à l'échelle, l'algorithme cherche, pour chaque point, si les autres points sont à une distance suffisamment proche de lui : une implémentation simple aboutit à une complexité quadratique. En fait l'algorithme peut être aussi implémenté en n.log(n) en effectuant une recherche plus intelligente. Cependant les packages proposés n'ont pas toujours cette implémentation.

Fuzzy-C Means

Le fuzzy clustering (également appelée soft clustering) est une forme de clustering dans laquelle chaque point de données peut appartenir à plusieurs clusters. L'un des algorithmes de fuzzy clustering le plus utilisé est l'algorithme FCM (Fuzzy C-means Clustering).

11.3.3 Analyse d'association

Méthode de Louvain

C'est un algorithme hiérarchique proposé dans Blondel et al. (2008) qui itère sur deux étapes :

1. Il cherche les petites communautés en optimisant la modularité de Newman et Girvan (2004) d'une manière locale ;
2. Il fusionne les nœuds de la même communauté et construit un nouveau réseau dont les nœuds sont les communautés. La partition qui a le maximum de modularité est retenue.

Deuxième partie

Clustering & Malware

Etat de l'art

Les progrès réalisés dans le domaine ces dernières années ont connu une croissance rapide général, l'ensemble des données qui ont contribué à ces progrès sont accessibles publiquement (papier de recherche etc. ...). La présence de l'ensemble de ces données de références publiques et opensource nous permettent de suivre les progrès réalisés sur le terrain.

Cependant, bien que les données ne manquent pas pour de nombreuses applications de machine learning, les chercheurs en sécurité sont confrontés au problème inverse. Les jeux de données de référence on tendance à manquer. Ceci peut s'expliquer en partie en raison de la présence d'informations personnelles identifiables ou encore d'informations sensibles sur l'infrastructure réseau ou de propriété intellectuelle privée.

Le tableau n'a pas pour objectif d'être exhaustif, mais permet de comparer les jeux de données généralement utilisés dans les différentes recherches académiques.

Implémentation

13.1 Introduction

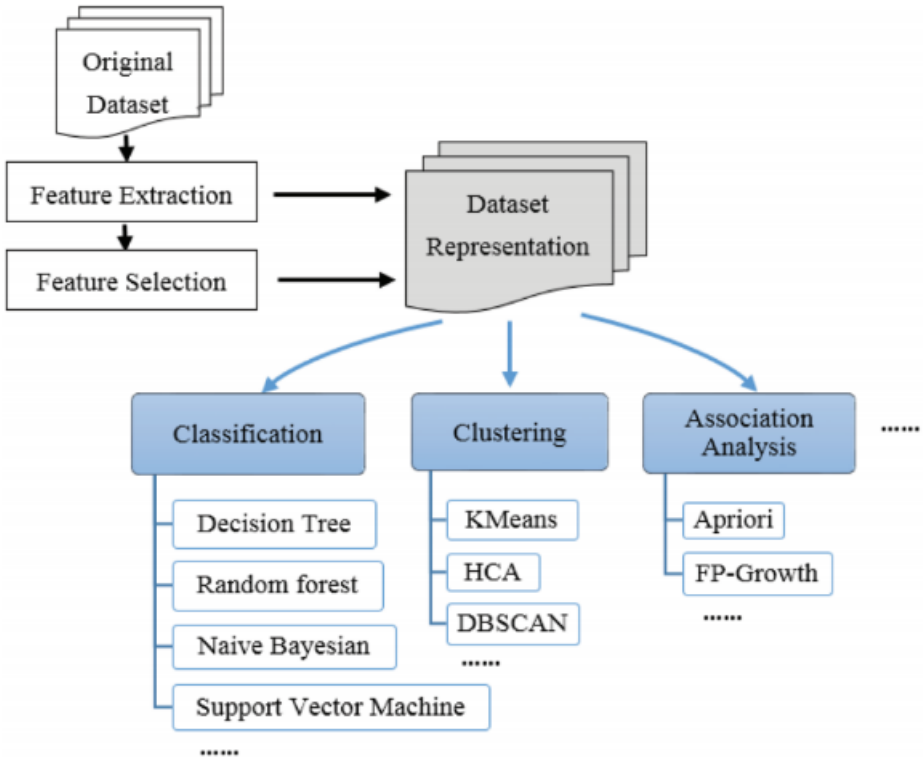

Ci-dessus se trouve le déroulement classique de la création d'un modèle de machine learning. L'un des gros problèmes est de trouver un jeu de données correctes et exploitable. Une fois le jeu de données, il faut en extraire des éléments discriminant (réalisés par un expert sécurité). Des tests sont ensuite effectués afin de déterminer quelles sont les éléments discriminant qui permettent une meilleure détection.

13.2 Sélections des attributs

L'étape d'extraction d'attributs est quant-à-elle spécifique à chaque problème de détection.

Dans le format PE, nous pouvons déjà isoler plusieurs informations intéressantes qui nous permettront de faire la différence entre un programme légitime et un malware tel que les :

Sections : le nom, la taille, l'entropie, les caractéristiques ;
Imports : le nombre de modules, le nombre de symboles, les fonctions ;
Exports : le nombre de modules, le nombre de symboles, les fonctions, la taille du fichier.

Il est nécessaire de définir les attributs à extraire pour représenter les instances sous forme de vecteurs numériques :

- Les nombre de sections ;
- Les noms des sections ;
- L'entropie des sections ;
- Les DLL importées ;
- Les fonctions importées ;
- La distribution du jeu d'instruction x86.

13.3 Format des données - Extraction des features

Afin de construire notre modèle de détection via du machine learning, il est nécessaire de récolter des données d'apprentissage. Il faut donc construire un dataset.

Pour constituer notre dataset qui servira par la suite à l'entrainement de notre algorithme de machine learning, nous allons essayer de générer une collection de fichier au format JSON. Dans ces fichiers chaque ligne contiendra un objet JSON. Nous avons tenté de définir une structure permettant de regrouper suffisamment d'informations.

Chacun de ces objets inclut les types de données suivants :

Il y a quelques grands principes à respecter lors de la construction du jeu d'apprentissage. Tout d'abord, il doit comporter un nombre suffisant d'instances pour que le modèle de détection soit capable de généraliser correctement les comportements bénin et malveillant.

Exemple de fichier JSON généré pour un fichier :


```
{
        "size": 106496,
        "path": "/home/light/Documents/Cours_CDSI/ML/dataset/theZoo/malware
        "name": "0008065861f5b09195e51add72dacd3c4bbce6444711320ad349c7dab5
        "appeared": "2017-01",
        "label": "-1",
        "hashes": {
                "md5": "d2074d6273f41c34e8ba370aa9af46ad",
                "sha1": "5074ec3ca672f74ea05a7b5f0f52339fbf440f9b",
```

```
        "sha256": "0008065861f5b09195e51add72dacd3c4bbce6444711320a
},
"nb_sections": 6,
"nb_exported_fonctions": 7,
"nb_imported_fonctions": 95,
"exported_fonctions": ["CON", "Fdown", "Fdown2", "InetReadF", "_Com
"imported_fonctions": ["InternetOpenA", "DeleteUrlCacheEntry", "Int
"imported_libraries": ["WININET.dll", "KERNEL32.dll", "ADVAPI32.dll
"general": {
        "vsize": 118784,
        "has_debug": 1,
        "exports": 7,
        "imports": 95,
        "has_relocations": 1,
        "has_resources": 1,
        "has_signature": 0,
        "has_tls": 0,
        "symbols": 0,
        "entrypoint": "0x100055dc"
},
"header": {
        "coff": {
                "timestamp": 1383637370,
                "machine": "I386",
                "characteristics": ["CHARA_32BIT_MACHINE", "DLL", "
        },
        "optional": {
                "subsystem": "WINDOWS_GUI",
                "dll_characteristics": [],
                "magic": "PE32",
                "major_image_version": 0,
                "minor_image_version": 0,
                "major_linker_version": 7,
                "minor_linker_version": 10,
                "major_operating_system_version": 4,
                "minor_operating_system_version": 0,
                "major_subsystem_version": 4,
                "minor_subsystem_version": 0,
                "sizeof_code": 65536,
                "sizeof_headers": 4096,
                "sizeof_heap_commit": 4096
        }
},
"sections": [{
        "name": ".text",
        "characteristics": 1610612768,
        "vsize": "0xf2eb",
        "size": "0x10000",
        "vaddres": "0x1000",
        "entropy": 6.625413677157515
```

```
        }, {
                "name": ".rdata",
                "characteristics": 1073741888,
                "vsize": "0x3a3b",
                "size": "0x4000",
                "vaddres": "0x11000",
                "entropy": 5.043471612579925
        }, {
                "name": ".data",
                "characteristics": 3221225536,
                "vsize": "0x3358",
                "size": "0x1000",
                "vaddres": "0x15000",
                "entropy": 2.7813728969479183
        }, {
                "name": ".SHARDAT",
                "characteristics": 3489660992,
                "vsize": "0x8",
                "size": "0x1000",
                "vaddres": "0x19000",
                "entropy": -0.0
        }, {
                "name": ".rsrc",
                "characteristics": 1073741888,
                "vsize": "0x368",
                "size": "0x1000",
                "vaddres": "0x1a000",
                "entropy": 3.2077393530680016
        }, {
                "name": ".reloc",
                "characteristics": 1107296320,
                "vsize": "0x1630",
                "size": "0x2000",
                "vaddres": "0x1b000",
                "entropy": 5.857932346902008
        }]
}
```


13.4 Choix technologiques

Afin d'implémenter notre algorithme de machine learning et d'effectuer des tests, nous avons parcouru l'ensemble des technologies disponibles aujourd'hui et voici celles que nous avons retenue :

13.4.1 Redis

REmote DIctionary Server (qui peut être traduit par ”serveur de dictionnaire distant” et jeu de mot avec Redistribute) est un système de gestion de base de données clef-valeur scalable, très hautes performances, écrit en C ANSI et distribué sous licence BSD. Il fait partie de la mouvance NoSQL et vise à fournir les performances les plus élevées possibles.

Nous aurions pu utiliser d'autres bases de données noSQL tel que Spark, MongoDB qui sont très utilisés dans le BigData.

13.4.2 SciPy

SciPy est un projet visant à unifier et fédérer un ensemble de bibliothèques Python à usage scientifique. Scipy utilise les tableaux et matrices du module NumPy. Cette distribution de modules est destinée à être utilisée avec le langage interprété Python.

13.4.3 Scikit-learn

Nous avons utilisé Scikit-learn qui est une bibliothèque libre Python dédiée à l'apprentissage automatique. Il existe beaucoup d'autres bibliothèque Python tel que ”TensorFlow” ou encore ”PyTorch”. Suite à nos recherches, Scikit learn semblait être la bibliothèque la plus documentée et possédée une très grande communauté d'utilisateurs.

13.4.4 LIEF : Library to Instrument Executable Formats

Pour notre projet comme de nombreux autres, nous avons besoin d'analyser les formats exécutables. La majorité des projets ré-implémentent généralement leur propre analyseur de fichier exécutable.

Dans les délais impartie, étant donné que nous ne maîtrisons pas suffisamment bien le format PE, il n'est pas envisageable de développer de zéro un parser de fichier. De plus, ces parseurs de fichier sont généralement liés à un langage de programmation particulier.

LIEF : Library to Instrument Executable Formats est un projet initié par QuarksLab qui a pour objectif d'offrir une librairie cross platform qui peut parser et modifier les différents formats de fichier ELF, PE, MachO. Cette librairie offre une couche d'abstraction. Le projet fournit une API Python C/C++.

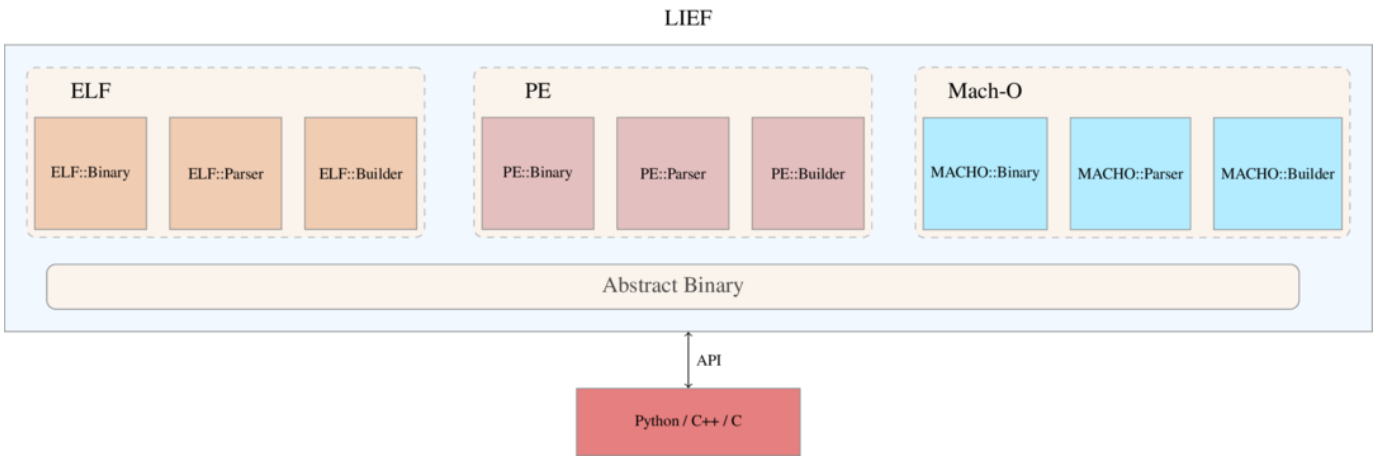

13.4.5 Capstone engine

Il s'agit d'un framework de multiplateforme et multiarchitecture qui permet le désassemblage de fichier.

13.4.6 Radare2

Il s'agit d'un framework de reverse engineering, il embarque le moteur capstone pour le désassemblage. Radare2 est instrumentale en Python à travers r2pipe.

Code - Python

Nous avons utilisé le repository "TheZoo" comme dataset dans un premier temps, car celui-ci contient des malwares et est disponible sur github.

Notre projet est composé de divers scripts que vous retrouverez sur github à cette adresse : `https://github.com/lightoyou/Malware_Clustering_ML`.

Nous allons les parcourir ensemble afin de comprendre leurs objectifs.

- Le premier script est **PEtoJSON.py**
  Ce script permet à partir d'un jeu de données binaires grâce à la librairie LIEF d'extraire les informations sur les fichiers de façon statique. Le script prend en entré un répertoire où il va naviguer de façon récursive afin de passer sur chaque fichier. A l'issue de la procédure un fichier au format JSON portant le SHA-256 du fichier est créé dans le répertoire nommé "jsonfiles". Des améliorations sont encore possibles (extraction de strings etc. ...), cependant les informations essentielles sont actuellement présentes (exemple présenté précédemment).

- Le second script est **extract_features.py**
  Ce script permet de parcourir l'intégralité des fichiers json, d'en isoler un vecteur de features : features = ["size_of_file","number_of_sections","median_of_entropy","nb_of_imports","number of exports"]
  Un second vecteur de features pourrait être mis en place afin de comparer les résultats, cependant par manque de temps nous n'avons pas testé. Nous utilisons un serveur Redis pour mettre en cache et améliorer les performances du traitement. La bibliothèque NumPy est utilisée afin de sauvegarder ce vecteur de feature sous forme de fichier ".npy".

- Les autres scripts sont **learnKmeans.py** et **learnDBSCAN.py**
  LearnKmeans utilise l'algorithme **KMeans** via la bibliothèque Sikit-learn.
  KMeans = KMeans(n_clusters=90,n_jobs=8,precompute_distances=False)
  Nous définissons le nombre de clusters (de catégories de malwares) ainsi que le nombre de jobs (pour effectuer le calcul).
  LearnDBSCAN utilise l'algorithme **DBSCAN** via la bibliothèque Sikit-learn.
- Le script **parse_vt_report.py**
  Nous pouvons continuer le processus sur un jeu de données plus conséquent. Nous avons commencé le travail sur les fichiers présents sur VirusShare. Il s'agit d'un gros dataset de fichiers malveillants. Nous avons au cours de nos recherches, récupérés des fichiers json contenant les rapports VirusTotal sur l'intégralité des malwares de VirusShare (utilisation de l'API par un groupe de recherche).

  Ces rapports permettent de labéliser l'intégralité du dataset aux travers des résultats de différents anti-virus. Un gros travail est à faire afin de normaliser ce jeu de données. Pour cela, nous avons

développé un script parse_vt_report.py qui permet de faire une prédiction sur la catégorie du bénin (ransomware, virus, ver etc. ...). Nous aurions voulu réaliser notre propre dataset afin d'effectuer à la fois de la classification et du clustering. Cependant, cette tâche est compliquée et nécessite beaucoup de travail nous ne sommes pas parvenu à cette étape. Nous aurions aimés continuer.

Globalement les fichiers manquent de documentation et de commentaires. Nous en sommes conscients.

Nos résultats

Dans cette partie nous allons essayés de choisir un type de modèle de classification adaptée aux contraintes opérationnelles et de comparer les résultats de détection obtenues sur différents algorithmes.

15.1 K-Means

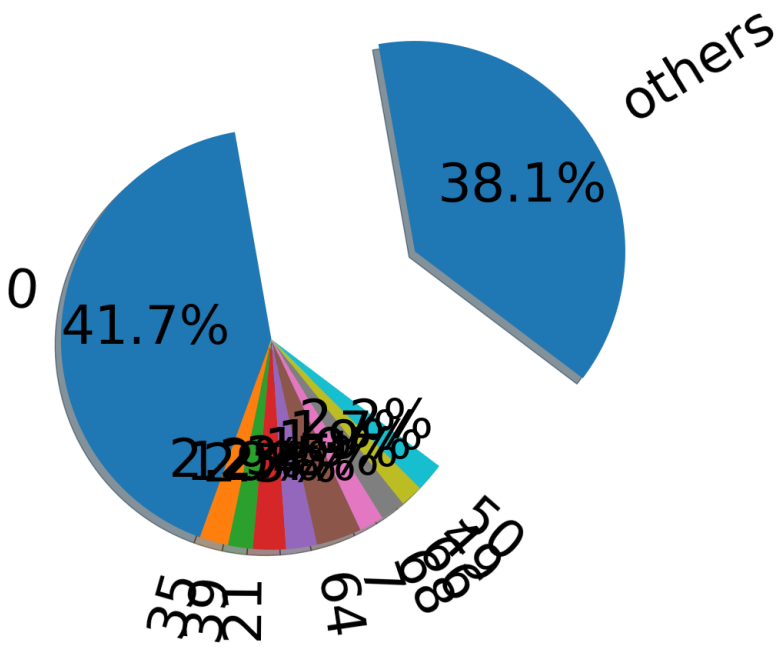

Ce graphique présente la distribution des malwares du dataset TheZoo que nous avons utilisés.

Nous pouvons noter deux grandes catégories :

Counter(b'EquationGroup' : 261, b'EquationGroup.Fanny' : 1, b'Backdoor.MSIL.Tyupkin' : 1, b'Ransomware.Locky' : 1)

Nous remarquons qu'un gros cluster de malware "EquationGroup" est majoritaire. Notre jeu n'est pas très homogène et n'est pas représentatif des fichiers pouvant être trouvés dans la nature.

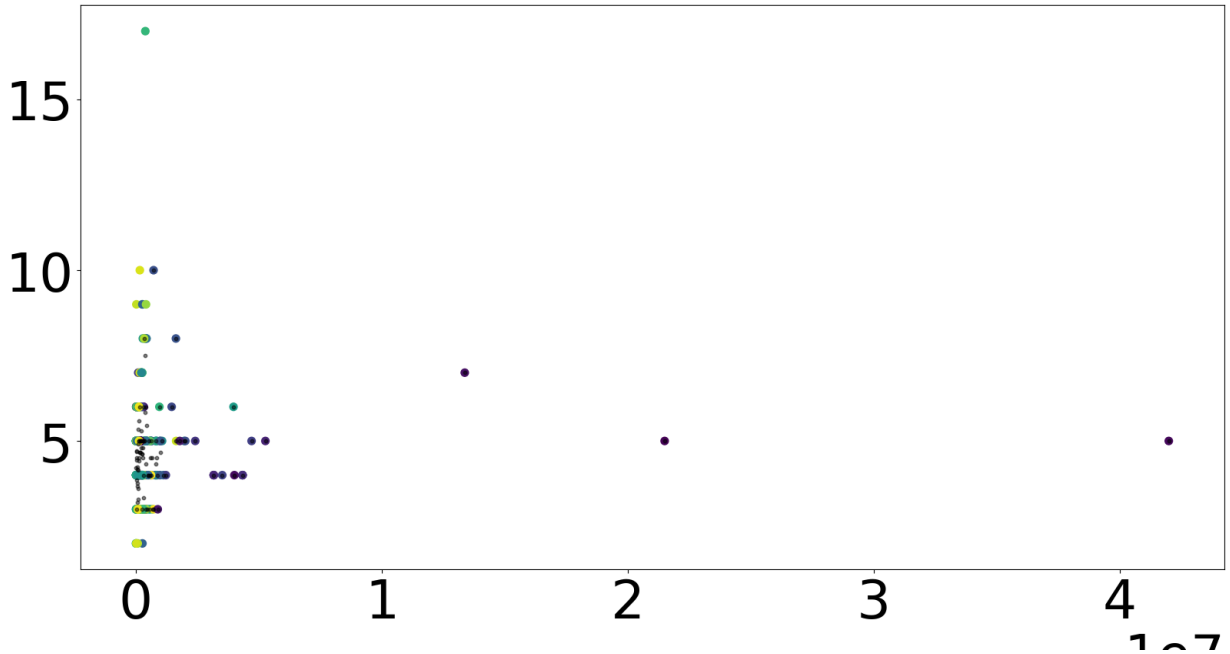

La figure ci-dessus permet de représenter la répartition du jeu de données par rapport au centroide.

15.2 DBSCAN

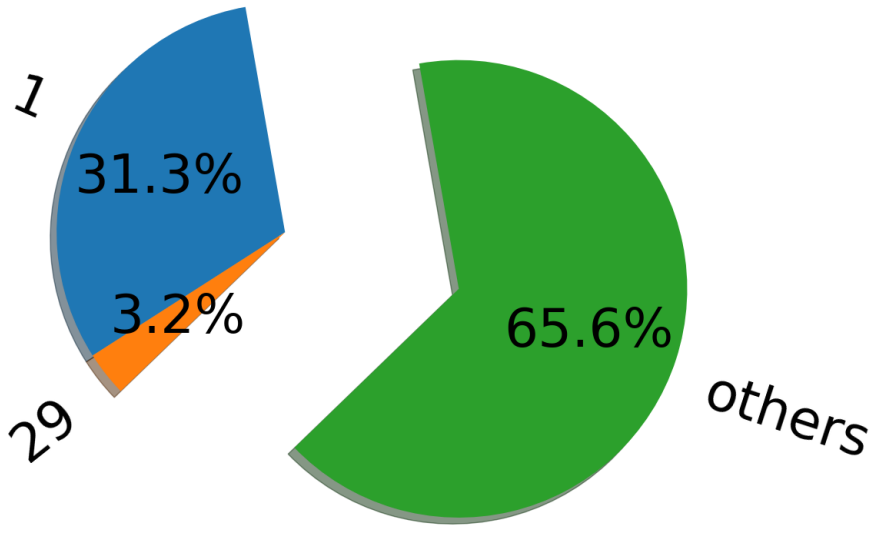

Catégorie 1 [(b'003315b0aea2fcb9f77d29223dd8947d0e6792b3a0227e054be8eb2a11f443d9', b'EquationGroup.Fanny'), (b'022224bfad26bab87cf5f4b17981a4224ef8fa6919520b3bc2946234efda1e11', b'EquationGroup'), (b'037bdc95919b1d3d65af6202e8c9c9ca3caba7a863e4e39162b93fa032881feb', b'EquationGroup'), (b'045f0ecae2362355f06d4fc8fa97e577daad1e01e6f0c0523b5b0f9e15306c74', b'EquationGroup'), (b'083c64c404ac1ea6df1a4cb6eafa91ef90b7abacc54547cf008cd74e77195746', b'EquationGroup'), b227be1967cd3b b'Equ

Catégorie 29 (b’12e8654f7ce06a2bfad58884cb44f745db618feae49dc17419857b491fbdca0c’, b’Equation-Group’), (b’140405af287d7d44ae06fdd169e8c3ee9033a7b3a43890a72114efb16b5a17cc’, b’EquationGroup’), (b’2e48d5bd7f6aba93f5a8af37defcd1b0cb6375335eeeceb3dc060ab6f7dcd2d7’, b’EquationGroup’), (b’3b96240880b b’EquationGroup’), (b’427c68a1c5ecb37a15af1cdfbaf9cc35448a4c148514f7b6c06a7ac266f76068’, b’Equa-tionGroup’),

Ces premiers résultats sont intéressants, mais pas totalement efficients. Quand on regarde la phase de normalisation du vecteur, la taille joue un rôle important. Cette feature a tendance à écraser les autres valeurs. Il pourrait donc être intéressant de normaliser en utilisant la valeur maximale de chaque features. La phase de normalisation est très importante.

Des tests approfondies sur d’autres algorithmes tel que **DBSCAN** sont nécessaires. D’autres vecteurs de features doivent être testés afin de comparer les résultats. L’intégration par exemple de vecteur tel que des chaînes de caractères (regex sur des registres, des urls etc. ...). Nous pouvons nous baser sur des travaux tel que les n-gram. Nous devons exploiter les résultats actuels afin de mieux comprendre et identifier les caractéristiques les plus pertinentes pour la classification.

Nos tests sur un petit jeu de données nous ont permis de comprendre le fonctionnement de base du machine learning.

Conclusion

À travers cet article nous pouvons en conclure que le machine learning ce n'est pas magique, un gros travail de featuring est nécessaire. Un bon jeu de données de départ est aussi très important. Le multi-architecture et l'extension vers d'autres types de virus que ceux ciblant Windows est facilement envisageable grâce à la bibliothèque LIEF.

Le machine learning est très utile pour faire un premier filtre afin de catégoriser un gros jeu de données comparé à des algorithmes de fuzzy hashing.

Utilisation de LightGBM : l'état actuel de nos travaux nous permet de conclure que cette méthode est pertinente et efficace car les résultats obtenus sont déjà très bons alors que de nombreuses pistes sont encore disponibles pour l'améliorer. Nous avons uniquement implémenté une solution permettant de faire du clustering, nous aimerions par la suite nous tourner vers des algorithmes de classification.

Glossaire

Machine Learning : Retrouver des patterns dans un jeu de données afin de les regrouper.

Classification : Classer les données dans des catégories prédéfinies. Les algorithmes sont par exemple : decision Tree, Random forest etc. …

Clustering : Regrouper les données dans un ensemble de catégories. Les algorithmes sont par exemple : KMEans, HCA, DBSCAN etc. …

Feature : Caractéristique d'un objet utile pour l'algorithme (les patterns potentiels).

Vector of features : Un tableau de features.

Cluster : Un groupe d'objets décidé par l'algorithme.

Label : Nom du cluster.

CFG : En informatique, un graphe de flot de contrôle (abrégé en GFC, Control Flow Graph ou CFG en anglais) est une représentation sous forme de graphe de tous les chemins qui peuvent être suivis par un programme durant son exécution.

JSON : JavaScript Object Notation (JSON) est un format de données textuelles dérivé de la notation des objets du langage JavaScript. Celui-ci permet de représenter de l'information structuré comme le permet XML par exemple.

Bibliographie

Schultz et al., 2001 : http://128.59.14.66/sites/default/files/binaryeval-ieeesp
pdf

Kolter and Maloof, 2006 : http://www.jmlr.org/papers/volume7/kolter06a/
kolter06a.pdf

Shafiq et al., 2009 : https://www.researchgate.net/profile/Fauzan_Mirza/
publication/242084613_A_Framework_for_Efficient_Mining_of_Structural_
Information_to_Detect_Zero-Day_Malicious_Portable_Executables/links/
0c96052e191668c3d5000000.pdf

Raman, 2012 : http://2012.infosecsouthwest.com/files/speaker_materials/
ISSW2012_Selecting_Features_to_Classify_Malware.pdf

Saxe and Berlin, 2015 : https://arxiv.org/pdf/1508.03096.pdf

James, 2017 : https://dfir.science/2017/07/How-To-Fuzzy-Hashing-with-SSDEEP
.html

Z. Liu et al., 2017 : https://www.riverpublishers.com/journal/journal_articles/
RP_Journal_2245-1439_631.pdf

Yara-Rules, 2017 : https://github.com/Yara-Rules/rules

Wikipedia, 2018 : https://en.wikipedia.org/wiki/Receiver_operating_characteri
Area_under_the_curve

Endgame, 2018 : https://github.com/endgameinc/ember/

Microsoft, 2016 : https://github.com/Microsoft/LightGBM

Bonneton et Husson, 2018 : https://www.sstic.org/media/SSTIC2017/SSTIC-actes/
le_machine_learning_confront_aux_contraintes_oprat/SSTIC2017-Article-le_
machine_learning_confront_aux_contraintes_oprationnelles_des_systmes_
de_dtection-bonneton_husson.pdf

yarocco, 2006 : https://repo.zenk-security.com/Reversing.cracking/LeformatPo
pdf

Chumachenko, 2017 : https://www.theseus.fi/bitstream/handle/10024/123412/
Thesis_final.pdf?sequence=1&isAllowed=y

Quarkslab, unknown : https://lief.quarkslab.com

pandas, 2018 : https://github.com/pandas-dev/pandas

Letois, 2017 : https://www.youtube.com/watch?v=aw5au9YCqSQ

Anderson, 2017 : https://www.blackhat.com/docs/us-17/thursday/us-17-Anderson
pdf

OpenAI, 2016 : https://gym.openai.com/

Pai, 2015 : http://scholarworks.sjsu.edu/cgi/viewcontent.cgi?article=1404&context=etd_projects

Vincelot, 2015 : https://www.quantmetry.com/single-post/2015/04/22/Clustering

Pinard, 2017 : https://assiste.com/Analyse_dynamique_de_malwares.html

Benzaki, 2017 : https://mrmint.fr/apprentissage-supervise-machine-learning